



POLITECHNIKA ŚLĄSKA
WYDZIAŁ INŻYNIERII BIOMEDYCZNEJ

Projekt z Bioniki

Wykorzystanie sieci neuronowych
do wyznaczania optymalnej ilości snu
dla konkretnego człowieka

Autor: Dawid Barański

Kierujący pracą: dr Barbara Mika

Zabrze, maj, 2018

Spis treści

1.	<i>Wstęp</i>	1
1.1	Cel projektu	1
1.2	Optymalna ilość snu	1
1.3	Zaburzenia powodowane brakiem snu	1
1.4	Jakość snu	2
1.5	Charakterystyka snu	3
1.5.1	Fazy snu	3
1.5.2	Stadia fazy NREM	3
2.	<i>Sieć neuronowa</i>	5
2.1	Perceptron	6
2.2	Rekurencyjna sieć neuronowa	7
2.3	LSTM	7
3.	<i>Informacje techniczne</i>	9
4.	<i>Dane wejściowe</i>	10
4.1	Zbieranie danych	10
4.2	Przygotowywanie danych	11
5.	<i>Model sieci</i>	12
5.1	Wejścia sieci	12
5.2	Wyjścia sieci	12
5.3	Powłoki	12
6.	<i>Wyniki</i>	14
6.1	Trudności rozwiązania	15
6.2	Dodatek	15
7.	<i>Wnioski</i>	17
8.	<i>Dalszy rozwój projektu</i>	19
	<i>Bibliografia</i>	20

Spis rysunków

1.1	Przykładowy podział stadiów snu z opaski fitness.	4
2.1	Schemat wielowarstwowej sieci neuronowej.	5
2.2	Porównanie komórki nerwowej z jej modelem.	6
2.3	Schemat perceptronu.	7
2.4	Schemat rekurencyjnej sieci neuronowej.	7
2.5	Schemat sieci LSTM.	8
4.1	Przykładowe dane snu z opaski fitness.	10
5.1	Zaprojektowana sieć neuronowa.	13
6.1	Predykcja jakości snu.	14
6.2	Funkcja błędu średniokwadratowego od epok sieci.	15
6.3	Jakość snu badanego.	16
6.4	Dodatek: MLP do przewidywania snu.	16

Spis tabel

1.1	Zaburzenia powodowane krótkim snem	2
1.2	Stadia snu NREM	3

1. Wstęp

„Sen to stan obniżenia wrażliwości na bodźce, częściowej bezwładności i zwolnienia funkcji, połączony ze zniesieniem świadomości, występujący u człowieka i zwierząt wyższych w rytmie dobowym, na przemian z czuwaniem.” [7]

1.1 Cel projektu

Celem projektu było stworzenie narzędzia, służącego do wyznaczania optymalnej ilości snu dla konkretnego człowieka. Danymi były odczyty ilości i jakości snu z poprzednich dni.

1.2 Optymalna ilość snu

Z badań przeprowadzonych przez Centers for Disease Control and Prevention (CDC) [1] wynika, że zdrowy sen powinien trwać przynajmniej 7 godzin. Wśród młodzieży więcej, bo między 8 a 10 godzin.

Inne badania wykazały, że minimalna ilość snu, potrzebnego do prawidłowego funkcjonowania organizmu, to 6 godzin. Przy czym sen poniżej 4,5 godziny można uznać za niebezpieczny dla komórek nerwowych mózgu.

Nie jest jednak możliwe, wyznaczenie jednej optymalnej ilości snu dla wszystkich ludzi. Duży wpływ na regenerację organizmu ma nie tylko ilość, ale także jakość snu.

1.3 Zaburzenia powodowane brakiem snu

Długoterminowe badanie Gallup z 2013 roku wykazało, że wśród Amerykanów 40% społeczeństwa śpi poniżej 6 godzin. Należy zauważyć, że wśród ostatnich 30 lat, ilość snu ustaliła się na równym poziomie. 14% Amerykanów sypia mniej niż 5 godzin na dobę, jednak w latach 40 było to zaledwie 3%. Problem dotyczy też nastolatków, 2/3 z nich sypia mniej niż 8 godzin. Dostarczanie organizmowi zbyt małej ilości snu może wpływać na ryzyko zachorowań na wiele chorób.

W tabeli (Tab. 1.1) przedstawiono wyniki badań dotyczących występowania 10 chronicznych chorób, w porównaniu do ilości snu. Jako próg przyjęto 7 godzin snu. Przebadano 2000 osób ze standardowej populacji. Wykazano jednoznacznie, że dłuższy sen pozytywnie wpływa na nasze zdrowie. Może chronić przed takimi chorobami jak nowotwór czy cukrzyca.

Tab. 1.1: Zaburzenia powodowane krótkim snem

	Krótki sen (<7 godzin)		Sen (>7 godzin)	
	%	95% P	%	95% P
Przewlekłe schorzenie				
Atak serca	4.8	(4.6–5.0)	3.4	(3.3–3.5)
Choroba wieńcowa serca	4.7	(4.5–4.9)	3.4	(3.3–3.5)
Udar mózgu	3.6	(3.4–3.8)	2.4	(2.3–2.5)
[1] Astma	16.5	(16.1–16.9)	11.8	(11.5–12.0)
Obturacyjny bezdech senny	8.6	(8.3–8.9)	4.7	(4.6–4.8)
Nowotwór	10.2	(10.0–10.5)	9.8	(9.7–10.0)
Artretyzm	28.8	(28.4–29.2)	20.5	(20.2–20.7)
Depresja	22.9	(22.5–23.3)	14.6	(14.3–14.8)
Przewlekła choroba nerek	3.3	(3.1–3.5)	2.2	(2.1–2.3)
Cukrzyca	11.1	(10.8–11.4)	8.6	(8.4–8.8)

1.4 Jakość snu

Poprzez jakość snu definiuje się możliwość regeneracji organizmu podczas snu w jednostce czasu. Istotny wpływ ma środowisko w jakim żyjemy, uwarunkowania genetyczne oraz sytuacje wynikające z konkretnego dnia. Za wprowadzenie w stan snu i jego jakość odpowiada hormon melatonina.

”Melatonina jest wytwarzana w nocy, niezależnie od tego o jakiej porze śpimy. Produkowana wyłącznie w ciemności. Prawdopodobnie wzrasta po przyjęciu pokarmu.”
 [4] Jest najważniejszym czynnikiem wpływającym na jakość snu. Wśród czynników środowiskowych, negatywnie oddziałujących na sen, można wymienić stresujący tryb życia, zmienną porę snu, czy brak aktywności fizycznej.

Według National Sleep Foundation, głównymi kluczami determinującymi jakość snu są:

- czas snu w odniesieniu do całkowitego czasu w łóżku (przynajmniej 85%)
- zasypianie w mniej niż 30 minut
- maksymalnie jedno przebudzenie w ciągu nocy
- przebudzenie trwające nie dłużej niż 20 minut

Szczegółową charakterystykę snu można przeprowadzić, stosując badanie elektroencefalograficzne (EEG). Wynikiem jest wykres bioelektrycznej czynności mózgu. Analizując pracę mózgu, można wyróżnić fazy.

Tab. 1.2: Stadia snu NREM

Fale EEG	Zakres częstotliwości [Hz]	Amplituda [μ V]
alfa	8-13	20-200
beta	13-30	5-10
delta	1-5	20-200
theta	4-8	10

1.5 Charakterystyka snu

1.5.1 Fazy snu

Sen dzieli się na dwie fazy:

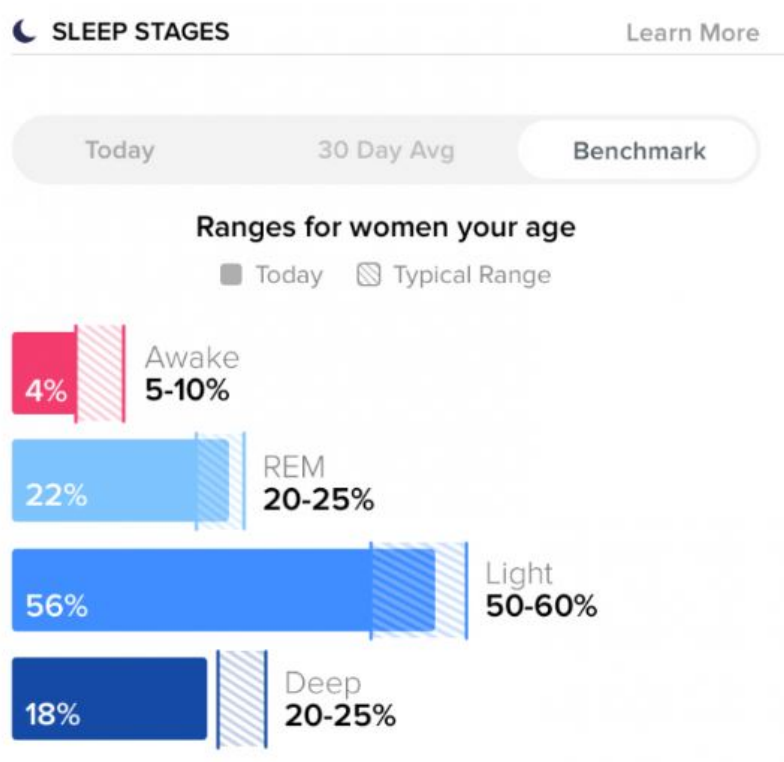
- faza NREM (z ang. non-rapid eye movement) to sen wolnofalowy - mózg wyłącza większość funkcji, oddech staje się regularny, spada ciśnienie tętnicze, napięcie mięśni zanika, a co najważniejsze do krwi uwalniany jest hormon wzrostu.

- faza REM (z ang. rapid eye movement) to sen paradoksalny – sen o szybkich ruchach gałek ocznych. Mięśnie się rozluźniają, pojawiają się marzenia senne, bodźce pochodzące z zewnątrz są ignorowane, występuje paraliż senny (mięśnie szkieletowe są zwiotczone). Występuje wysoka aktywność mózgu. Choć nieznana jest dokładna funkcja tej fazy to deprawacja snu REM u szczurów prowadzi do śmierci w ciągu kilku tygodni.

1.5.2 Stadia fazy NREM

Sen wolnofalowy jest znacznie lepiej zbadany przez naukowców. Możemy wydzielić 4 jego stadia, według częstotliwości fal elektrycznych. Ich specyfikację przedstawiono w tabeli (Tab. 1.2).

Ułatwieniem do przeprowadzania badań nad snem, są opaski fitness i smartwatche. Nie są to urządzenia dokładne jak EEG czy elektrokardiograf (EKG). Dużą zaletą jest jednak to, że mogą rejestrować wyniki dużo częściej niż tradycyjne urządzenia i w dłuższym okresie czasu. Nie wymagają przy tym od użytkownika żadnych umiejętności i nie utrudniają życia. Na rysunku (Rys 1.1) przedstawiono estymowany procentowy udział stadiów i faz snu dla 30 letniej kobiety z porównaniem do innych kobiet w jej wieku. Dane te mogą posłużyć do analizy snu i przewidywania zachowań poprzez stworzenie sztucznej sieci neuronowej.




Rys. 1.1: Przykładowy podział stadiów snu z opaski fitness.

2. Sieć neuronowa

„Sieć neuronowa (sztuczna sieć neuronowa) – ogólna nazwa struktur matematycznych i ich programowych lub sprzętowych modeli, realizujących obliczenia lub przetwarzanie sygnałów poprzez rzędy elementów, zwanych sztucznymi neuronami, wykonujących pewną podstawową operację na swoim wejściu. Oryginalną inspiracją takiej struktury była budowa naturalnych neuronów, łączących je synaps, oraz układów nerwowych, w szczególności mózgu.

Czasem nazwą sztuczne sieci neuronowe określa się interdyscyplinarną dziedzinę wiedzy zajmującą się konstrukcją, trenowaniem i badaniem możliwości tego rodzaju sieci.” [8]




Rys. 2.1: Schemat wielowarstwowej sieci neuronowej.

Na rysunku (Rys. 2.1) przedstawiono schemat sztucznej sieci neuronowej. Elementami składowymi są wejścia, ukryte powłoki z wagami oraz wyjścia sieci. Ilość powłok zależy od konkretnych zastosowań i nie jest jednoznaczna.

2.1 Perceptron

Najprostrzą siecią neuronową może być sztuczny neuron. Jest niedoskonałym i uproszczonym modelem biologicznego neuronu, który jest zasadniczym elementem strukturalnym mózgu. Porównanie neuronu oraz jego modelu przedstawiono na rysunku (Rys. 2.2).




Rys. 2.2: Porównanie komórki nerwowej z jej modelem.

Rysunek (Rys. 2.3) przedstawia schemat perceptronu. Jako x oznaczono wejścia sieci, w - wagi neuronów, y to wyjście neuronu. Są to typowe oznaczenia stosowane w sieciach neuronowych. Od zwykłego sztucznego neuronu różni się tym, że zawiera funkcję aktywacji, która zmienia wartość wyjścia, poprzez implementację wybranej funkcji. Do najczęściej używanych funkcji aktywacji należą:

- funkcja liniowa
- funkcja progowa
- funkcja sigmoidalna unipolarna
- funkcja sigmoidalna bipolarna (tangens hiperboliczny)
- funkcja Gaussa


Wynikiem działania perceptronu jest wartość z przedziału 0-1. W szczególnych przypadkach - binaryzacji - wartość wynosi dokładnie 0 lub 1.



Rys. 2.3: Schemat perceptronu.

2.2 Rekurencyjna sieć neuronowa

Ludzki mózg nie zaczyna żadnego swojego działania od zera. Każde nasze działanie bazuje na doświadczeniach, które są składowane w pamięci. Podobnie działa rekurencyjna sieć neuronowa (RNN - z ang. *Recurent Neural Network*). Każda iteracja algorytmu uwzględnia dane z poprzednich obliczeń, co przedstawia rysunek (Rys. 2.4). Dzięki temu sieć rozumie kontekst. Sieci te stosuje się do rozpoznawania obrazów, rozpoznawania mowy, tłumaczenia języków.




Rys. 2.4: Schemat rekurencyjnej sieci neuronowej.

2.3 LSTM

Long short-term memory (LSTM) jest specjalnym typem sieci rekurencyjnych. Technika ta nie posiada polskiego tłumaczenia. Pozwala na uczenie długoterminowych zależności, które są ich typowym zastosowaniem.

Model sieci LSTM przedstawia się następująco: (Rys. 2.5).



Rys. 2.5: Schemat sieci LSTM.

LSTM używa wewnątrz swojej powłoki dwóch funkcji aktywacji: sigmoidy unipolarnej oraz tangensa hiperbolicznego. Informacje łączą się za pomocą operacji mnożenia lub dodawania.

Schemat działania pojedynczego neuronu składa się z 4 kroków(4 bram). Pierwszym z nich jest decyzja o tym, czy przyjętą informację należy zapamiętać. Decyzja jest podejmowana w oparciu o sigmoidę - jeśli wynikiem jest 0 - następuje całkowite zamknięcie bramy i zapomnienie informacji. 2 i 3 krokiem jest decyzja jakie wartości i z jakimi wagami należy zapamiętać w pamięci sieci. Wynik tej operacji wędruje do węzła sumacyjnego. Ostatnim krokiem jest obliczenie wartości wyjścia sieci na podstawie poprzednich wyników oraz wszystkich wejść sieci.

Bardzo dobry, szczegółowy artykuł o tym jak działa RSTM można przeczytać pod linkiem [6]. Rysunki o RNN zostały zaczerpnięte właśnie z tego źródła.

3. Informacje techniczne

Kod programu został napisany w języku *Python* w wersji 3.6. Jako środowiska programistycznego użyto *Spyder*. Korzystano z bibliotek: do sieci neuronowych *Keras*, który jako silnika używa biblioteki *Tensorflow*, do obliczeń matematycznych: *sklearn*, do tworzenia wykresów: *matplotlib*. Dane pochodzące od badanego były przechowywane w pliku CSV.

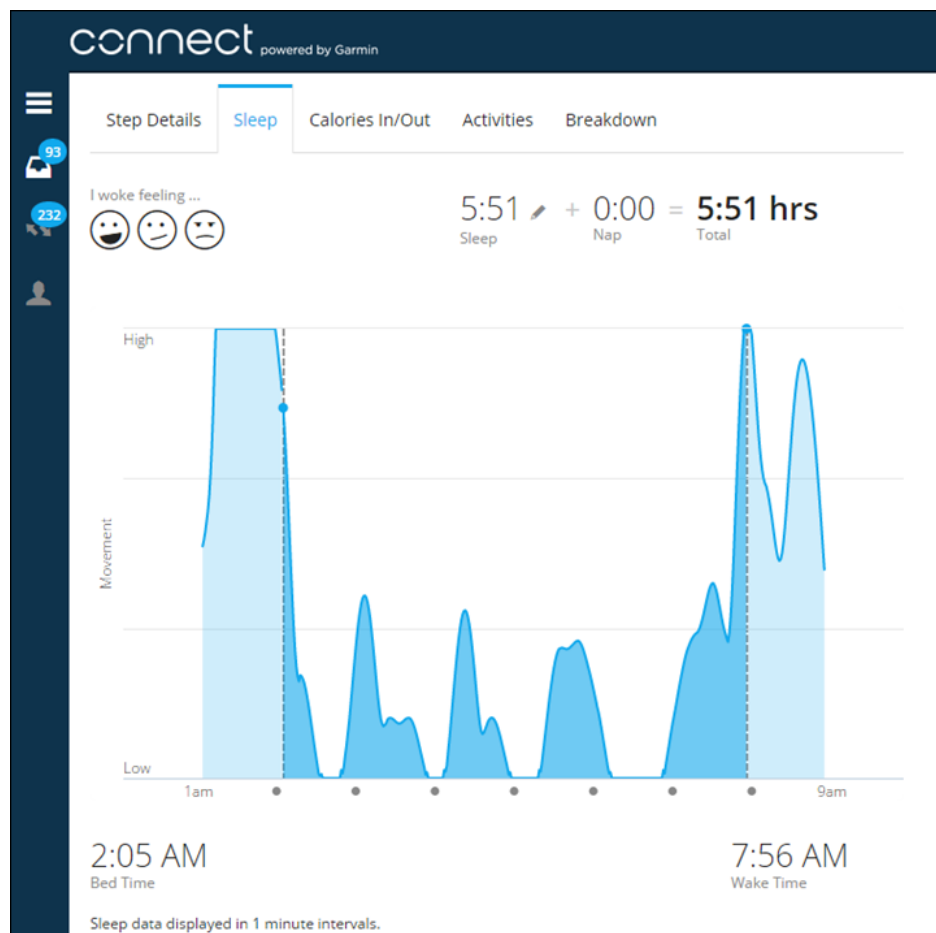
Cały projekt był prowadzony i publikowany na bieżąco w serwisie: *github.com*. Postępy prac, kod oraz sprawozdanie projektowe są dostępne pod adresem:

<https://github.com/dawidb1/Bionika-projekt>

4. Dane wejściowe

4.1 Zbieranie danych

Dane do sieci neuronowej zostały zebrane za pomocą opaski fitness *Xiaomi Mi Band 2* oraz telefonu z systemem *Android* z zainstalowaną aplikacją *Mi Fit*. Opaska umożliwia monitorowanie snu. Dane są zbierane poprzez akcelerometr, który służy do pomiaru przyspieszeń liniowych i kątowych. Aplikacja analizuje te dane i na ich podstawie estymuje czas snu lekkiego i głębokiego, według ruchowej aktywności w nocy. Przykładowe interpolowane już dane z jednej nocy przedstawiono na rysunku (Rys. 4.1).



Rys. 4.1: Przykładowe dane snu z opaski fitness.

Za pomocą tej metody zebrano dane snu z 200 dni, od jednej osoby w wieku 16 lat.

4.2 Przygotowywanie danych

Dane do sieci muszą zostać znormalizowane. Do tego celu użyto gotowej funkcji *MinMaxScaler* z biblioteki *sklearn.preprocessing*. Funkcja korzysta ze wzoru:

$$x_{odch} = \frac{x - \min(X)}{\max(X) - \min(X)}$$

$$x_{norm} = x_{odch} * (\max - \min) + \min$$

Przy czym:

- x to dana wejściowa
- X to zbiór danych typu x
- $\min(X)$ to minimum całego zbioru
- \min to najmniejsza liczba po normalizacji

Normalizację przeprowadzono do wartości z przedziału 0-1.

Niektóre z danych były formatu: data-czas. W tym wypadku obliczono ilość czasu od północy w minutach. Dodatkowo dostarczano dane o dniu tygodnia - dni zostały zamienione na liczby całkowite z przedziału 0-6. Wszystkie dane wejściowe zostały znormalizowane.

Jako, że testowany typ sieci uczy się z nadzorem, zbiór danych podzielono na zbiór uczący oraz testowy w proporcji 0.85/0.15.

LSTM z każdą iteracją przetwarza nie tylko jedno wejście, ale także wejścia z poprzednich iteracji. Dlatego jako wejścia należało przygotować tablicę składającą się z 3 wymiarów: wejścia sieci, codzienne dane oraz wektory z danymi z poprzednich x iteracji, gdzie x oznacza liczbę poprzednich kroków, które bierzemy pod uwagę w sieci.

5. Model sieci

5.1 Wejścia sieci

Jako wejścia sieci ustalono:

- czas zaśnięcia
- czas obudzenia
- dzień tygodnia

5.2 Wyjścia sieci

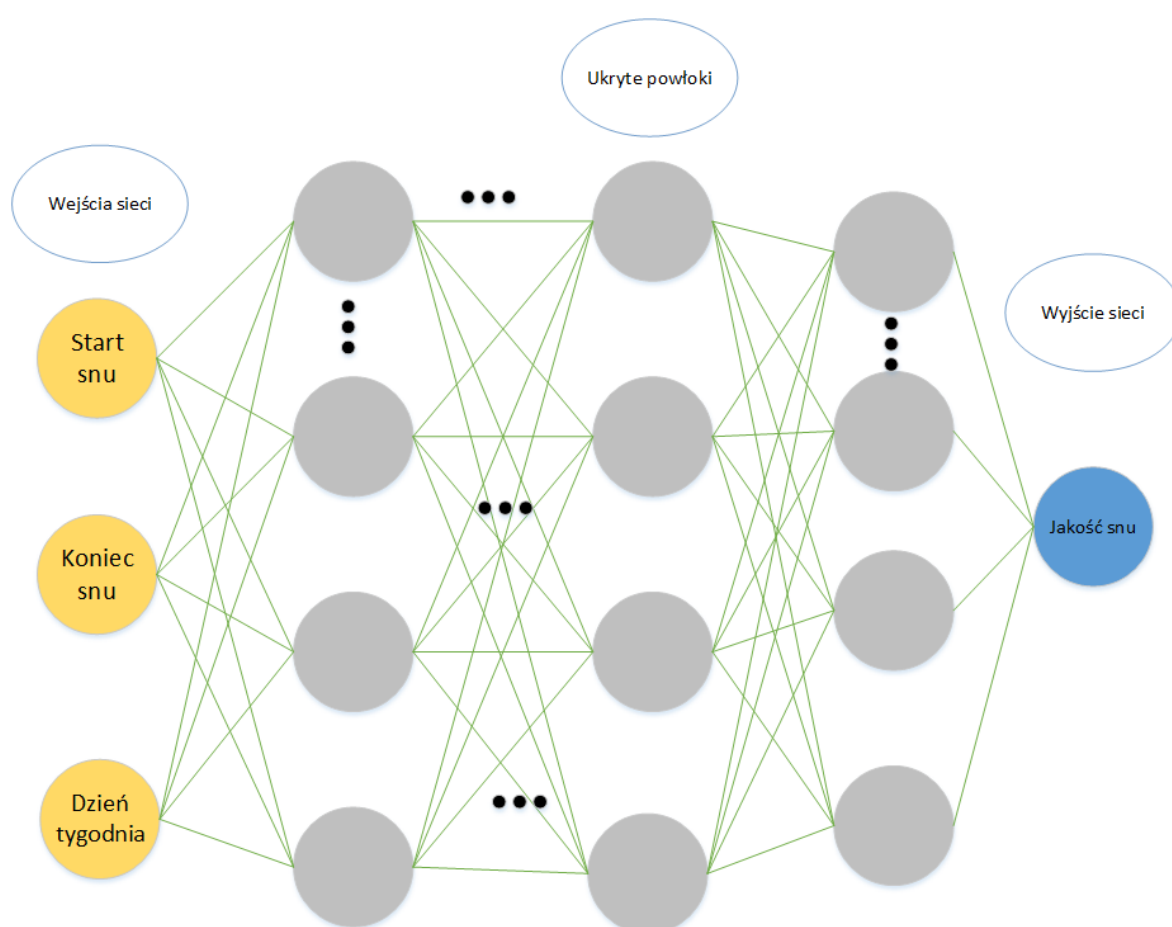
Wyjściem sieci jest jakość snu definiowana jako:

$$\text{Jakość snu} = \frac{\text{Ilość snu głębokiego}}{\text{Całkowita ilość snu}}$$

5.3 Powłoki

W trakcie badań wyznaczono doświadczalnie sieć składającą się z 4 powłok z 50 neuronami na każdej powłoce.

Rysunek (Rys. [5.1](#)) przedstawia model zaprojektowanej sieci neuronowej.



Rys. 5.1: Zaprojektowana sieć neuronowa.


6. Wyniki

Podczas badań sieci starano się dostosować parametry pod kątem najmniejszego błędu średniokwadratowego oraz najlepszego wizualnego dopasowania funkcji (uwzględniając przy tym zmiany wolnofalowe).


Doświadczalnie zostały wyznaczone następujące parametry:

- ilość epok: 1000
- dropout: 20%
- mini-batch: 8
- poprzednie kroki: 32

Na rysunkach (Rys. 6.1 i 6.2) przedstawiono najlepsze odwzorowanie zbioru testowego. Zbiór posiadał 30 danych wejściowych - czyli 30 dni.



Rys. 6.1: Predykcja jakości snu.



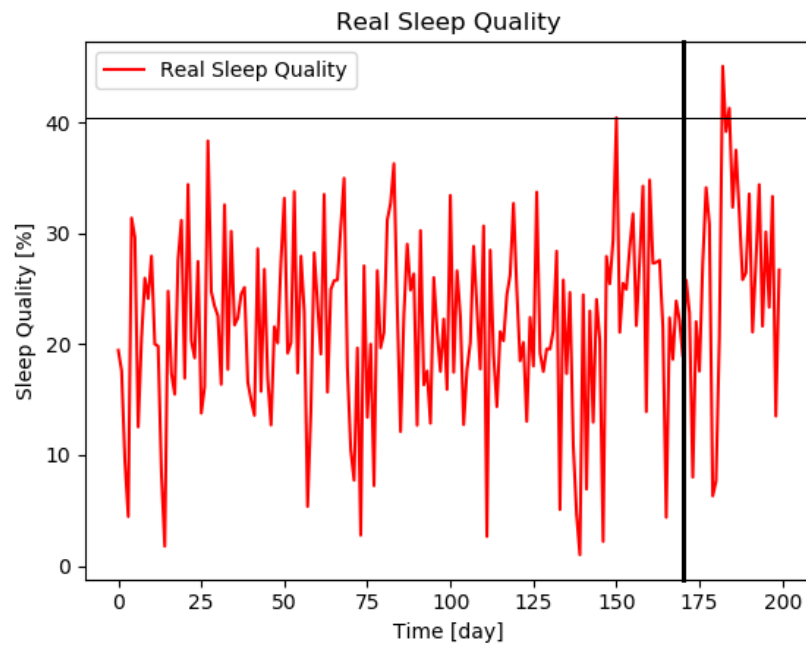
Rys. 6.2: Funkcja błędu średniokwadratowego od epok sieci.

6.1 Trudności rozwiązania


Wyznaczenie prawidłowych wyników przez sieć było bardzo trudne, ponieważ w ciągu ostatniego miesiąca, osoba badana odnotowała znaczny wzrost jakości snu. Przewidzenie takiego zachowania jest prawie niemożliwe dla sieci. Rysunek (Rys. 6.3) przedstawia jakość snu badanego w ciągu całego okresu akwizycji danych. Linia pionowa oddziela dane uczące sieć od danych testowych. Możliwym ulepszeniem algorytmu byłoby rozproszenie danych testowych wśród wszystkich danych. Jest to skomplikowany krok, ponieważ każda dana potrzebuje danych z poprzednich iteracji, jednak możliwe do osiągnięcia na większym zbiorze danych.

6.2 Dodatek

Na początku pracy z projektem rozważano zastosowanie prostej sieci wielowarstwowej (MLP z *ang.* *Multilayer perceptron*). Jednak sieć okazała się wychwytywać tylko jedno rozwiązanie funkcji, szybko się przeuczała - wyjście sieci nie zależało już od wejść, funkcja była okresowa. Można zobaczyć to na rysunku (Rys. 6.4). W tamtym algorytmie testowano 2 wyjścia sieci - czas obudzenia i jakość snu.



Rys. 6.3: Jakość snu badanego.



Rys. 6.4: Dodatek: MLP do przewidywania snu.

7. Wnioski

- Sieci neuronowe są interesującym do dalszych badań narzędziem do badania i przewidywania biologicznych zależności, na przykład zagadnienia snu.
- Nie udało się wyznaczyć dokładnej optymalnej ilości snu dla badanej osoby. Utworzono jednak sieć, która z zadowalającą dokładnością rozumie korelację między godzinami snu a jego jakością.
- Czas, jako dana używana w sieci, nie jest intuicyjnie rozumiana przez sieć. Sieci LSTM naturalnie powinny radzić sobie z tego typu informacjami, jednak zaimplementowanie ich do algorytmu, wiąże się z przyjęciem pewnej abstrakcji. Na skonstruowanie wejść czasowych nie ma jednego sposobu. Od przetworzenia tych danych zależy pomyślność wyników.
- Wybrana ilość poprzednich kroków (32) jest bardzo duża. Może to świadczyć o tym, że nasz sen zależy od wielu poprzednich dni.
- Dobór parametrów wpływa na wyniki. Często lepiej dodać więcej powłok i iteracji, tracąc trochę czasu, ale otrzymując nie gorsze wyniki. Należy jednak pamiętać o zjawisku przeuczenia sieci.
- Postęp uczenia sieci oraz jej prawidłowość, najlepiej oceniać, analizując błąd średniokwadratowy - ten sam, którego sieć używa do dopasowywania wag neuronów. Znaczące przy analizie i doborze parametrów jest wyrysowanie funkcji błędu średniokwadratowego od epok algorytmu. Bardzo łatwo w ten sposób dobrać odpowiednią ilość epok.
- Aby wnioski były w pełni poprawne, zamodelowana sieć neuronowa powinna być przebadana na większej liczbie badanych i większej liczbie próbek.
- Projekt ten łatwo rozszerzyć o kolejne dane i wejścia sieci.
- Porównywano używanie biblioteki Keras z silnikiem Tensorflow do tradycyjnego Tensorflow. Biblioteka Keras znacząco ułatwia pracę z sieciami neuronowymi. Pozwala zaimplementować dowolną sieć w kilku krokach. Na tym poziomie tworzenia i badania, jest to najlepszy wybór.
- Podczas realizowania projektu nauczyłem się podstaw Pythona oraz jego bibliotek. Nie stanowiło to jednak większego problemu w pracy. Całe środowisko jest intuicyjne, a biblioteki pozwalają na implementację kompletnych, gotowych funkcji

matematycznych, takich jak obliczanie błędu średniokwadratowego, normalizacje czy transponowanie macierzy.

8. Dalszy rozwój projektu

W przyszłości planowane jest zebranie większej ilości danych i dalsze testowanie sieci. Możliwe jest także stworzenie algorytmu, który na podstawie utworzonej w tym projekcie sieci, będzie przewidywał, o której należy położyć się spać, żeby najlepiej się wyspać. Na tą chwilę jednak, sieć nie jest wystarczająco przetestowana i wiarygodna, aby opierać na niej inne algorytmy i badania.

Planowane jest także rozszerzenie sieci o nowe wejścia. Na pewno znalazłyby się tam dane o aktywności fizycznej w ciągu dnia, które także można czytać z opaski fitness. Dodatkowo możliwe jest zebranie informacji o drzemkach w ciągu dnia oraz wypitych kawach.

Bibliografia

- [1] Sleep and sleep disorders. https://www.cdc.gov/sleep/data_statistics.html, 2017. [Online; dostęp 10.06.2018].
- [2] A. SATHYANARAYANA MSc, SHAFIQ JOTY PhD, L. F.-L. P. Sleep quality prediction from wearable data using deep learning. *JMIR Mhealth Uhealth* (2016).
- [3] LOBDELL, M. Study less study smart. [Online; dostęp 10.06.2018].
- [4] MAŁGORZATA LEHNER, ADAM HAMED, A. P. Regulacja rytmów okołodobowych na przykładzie melatoniny o powolnym uwalnianiu. *Kwartalnik Farmakoterapia w Psychiatrii i Neurologii* (2009).
- [5] NARDEAS. sleepnow. <https://github.com/nardeas/sleepnow>, 2017. [Online; dostęp 10.06.2018].
- [6] OLAH, C. Understanding lstm networks. <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>, 2015. [Online; dostęp 7.06.2018].
- [7] WICHNIAK, A., ALON AVIDAN, Y., AND PHYLLIS ZEE, C. *Podręcznik medycyny snu*. Medipage, Kraków, 2007.
- [8] WIKIPEDIA. *Sieć neuronowa*. Wikimedia Foundation, 2018.
- [9] YASSIN, G. Build Simple AI .NET Library - Part 3 - Perceptron. <https://www.codeproject.com/Articles/1205732/Build-Simple-AI-NET-Library-Part-Perceptron>, 2017. [Online; dostęp 10.06.2018].